

## Avaliações e temas e datas

### Datas das avaliações:

|                          |                   |
|--------------------------|-------------------|
| <u>Primeiro Trabalho</u> | <u>15/05/2026</u> |
| <u>Segundo Trabalho</u>  | <u>03/07/2026</u> |

- **Acessar essa planilha e escrever a composição dos grupos para a primeira e segunda avaliação:**  
[https://docs.google.com/spreadsheets/d/1rjfw7Ka0-ZOUlldbNWZyk7f\\_iM\\_FhmAg/edit?usp=drive\\_link&ouid=114295666175603983071&rtpof=true&sd=true](https://docs.google.com/spreadsheets/d/1rjfw7Ka0-ZOUlldbNWZyk7f_iM_FhmAg/edit?usp=drive_link&ouid=114295666175603983071&rtpof=true&sd=true)

Preencher até dia 10-04-2026, após essa data so vai apresentar quem entrar em contato comigo e de acordo com o número de dias de atraso descontarei 1 ponto por dia.

- **Dúvidas podem ser tiradas ao final de cada aula ou pelo email -> jasmine@ufpa.br.**

### **Trabalho 1 (Grupos de 5 Alunos)**

**:Usar as técnicas de Árvores de Decisão/Random Forest e Redes Neurais.**

**Objetivo:** Comparar as duas técnicas em termos de métricas de desempenho. Encontrar um dataset público adequado (Kaggle é recomendado, mas não obrigatório) e implementar ambos os modelos para resolver o problema descrevendo as performances de forma crítica e detalhada.

Passos Obrigatórios:

1. Definição do Problema e Escolha do Dataset:  
Pesquisem e selecionem um dataset público. Justifiquem a escolha do dataset, descrevendo seus atributos, tamanho e o que ele representa.
2. Pré-processamento dos Dados:  
Realizem uma análise exploratória dos dados (EDA - Exploratory Data Analysis).  
Apliquem as técnicas de limpeza e pré-processamento necessárias, como tratamento de dados faltantes, normalização/padronização das features e outras.
3. Implementação e Treinamento:  
Random Forest: Implementem o modelo, realizando um ajuste fino (tuning) de seus principais hiperparâmetros (ex: `n\_estimators`, `max\_depth`).  
Otimizar os hiperparâmetros da rede neural também.
4. Avaliação e Comparação:  
Dividam o dataset em conjuntos de treino e teste (e, opcionalmente, validação).  
Avaliem ambos os modelos usando um conjunto robusto de métricas de classificação. A comparação deve ser feita sobre o conjunto de teste.  
Métricas Obrigatórias:  
Acurácia (Accuracy): Visão geral do desempenho.  
Matriz de Confusão: Para visualizar os erros (Verdadeiros Positivos, Falsos Positivos, Verdadeiros Negativos, Falsos Negativos).  
Precisão (Precision): Dos que foram classificados como positivos, quantos realmente eram? (Importante quando o custo de um Falso Positivo é alto).  
Recall (Sensibilidade): Dos que eram realmente positivos, quantos foram capturados pelo modelo? (Importante quando o custo de um Falso Negativo é alto).  
F1-Score: A média harmônica entre Precisão e Recall, útil para datasets desbalanceados.  
Curva ROC e AUC: Para avaliar a capacidade de discriminação do modelo em diferentes limiares de classificação.

Entrega Final:

Um relatório técnico detalhado e uma apresentação. O relatório deve conter a descrição do problema, análise do dataset, metodologia, resultados (incluindo tabelas e gráficos comparativos das métricas) e uma discussão crítica sobre os resultados. A discussão deve abordar:

- Qual modelo se saiu melhor e por quê?
- Qual foi mais fácil e /ou rápido de treinar e ajustar?
- Qual oferece mais interpretabilidade?
- Em que situações um seria preferível ao outro?
- Quais foram os principais desafios do projeto?

## **Trabalho 2 (Grupos de 5 Alunos)**

Título do Trabalho: Desenvolvimento de um Sistema de Inteligência Computacional Híbrido ou Ensemble + **tema de cada grupo**

Objetivo:

Este projeto desafia o grupo a ir além da aplicação de um único algoritmo. O objetivo é projetar, implementar e avaliar um sistema inteligente mais complexo, que combine duas ou mais técnicas da ementa (ou relacionadas) para resolver um problema desafiador.

Diretrizes e Ideias de Arquitetura:

Os grupos devem escolher um problema (classificação, regressão, otimização, etc.) e um dataset público, e então propor uma solução baseada em uma das seguintes abordagens (ou outra de complexidade similar):

1. **Sistemas Híbridos (Neuro-Fuzzy, Genético-Neural, etc.):**  
Combinar técnicas de diferentes paradigmas da IA.  
Exemplo: Usar um Algoritmo Genético para otimizar os pesos ou a topologia de uma Rede Neural, ou usar a saída de um Sistema Fuzzy como uma feature de entrada para um modelo conexionista.
2. **Métodos de Ensemble Avançados:**  
Criar um "comitê de especialistas" onde múltiplos modelos (diversos entre si) colaboram para uma decisão final.
3. **Modelos Probabilísticos e Conexionistas:**  
Usar uma Rede Bayesiana para modelar as dependências entre variáveis e, em seguida, alimentar as probabilidades inferidas em uma Rede Neural para capturar relações não-lineares.

Entrega Final:

Um relatório técnico detalhado e uma apresentação. O relatório deve focar na justificativa da arquitetura escolhida:

- Por que a combinação de técnicas é promissora para o problema em questão?
- Como as diferentes partes do sistema se comunicam?
- Qual foi o ganho (ou perda) de performance em relação a uma abordagem mais simples (baseline)?
- Análise aprofundada dos resultados, desafios de implementação e possíveis trabalhos futuros.

**Nas apresentações os grupos terão 15 minutos para apresentar. Quem exceder esse tempo perderá a cada 5 minutos excedido.**