



Árvores de Decisão


Prof. Jasmine Araújo
jasmine@ufpa.br

Baseado nos slides do Prof.
Ádamo Santana





Árvores de Decisão

- ❖ Representação, em uma estrutura de árvore, de um conjunto de regras de decisão. Formalmente, é um grafo acíclico direcionado em que cada nó ou é um nó de divisão, com dois ou mais sucessores, ou um nó folha.
- ❖ Cada ramo da árvore representa uma conjunção de condições (regras se...então)
- ❖ A capacidade de discriminação de uma árvore vem da:
 - Divisão do espaço definido pelos atributos em sub-espacos.
 - Associação de uma classe a cada sub-espaco.





Árvores de Decisão (simplificando)





Árvores de Decisão (um exemplo)

categorical categorical continuous class


	Tid	Refund	Marital Status	Taxable Income	Cheat
X	1	Yes	Single	125K	No
X	2	No	Married	100K	No
	3	No	Single	70K	No
X	4	Yes	Married	120K	No
	5	No	Divorced	95K	Yes
X	6	No	Married	60K	No
X	7	Yes	Divorced	220K	No
	8	No	Single	85K	Yes
X	9	No	Married	75K	No
	10	No	Single	90K	Yes

Training Data

Refund – restituição

Cheat - Fraude

Taxable income – rendimentos tributáveis



Model: Decision Tree



Árvores de Decisão (um exemplo)

categorical categorical continuous class


Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	<u>No</u>	<u>Married</u>	100K	<u>No</u>
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	<u>No</u>	<u>Married</u>	60K	<u>No</u>
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	<u>No</u>	<u>Married</u>	75K	<u>No</u>
10	No	Single	90K	Yes

Training Data

Refund – restituição

Cheat - Fraude

Taxable income – rendimentos tributáveis



Model: Decision Tree



Árvores de Decisão (um exemplo)

categorical categorical continuous class


Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Training Data

Refund – restituição

Cheat - Fraude

Taxable income – rendimentos tributáveis




Model: Decision Tree



Árvores de Decisão (um exemplo)

categorical
categorical
continuous
class

<i>Tid</i>	<i>Refund</i>	<i>Marital Status</i>	<i>Taxable Income</i>	<i>Cheat</i>
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes




Um exemplo de outra AD, construída a partir dos mesmos dados de treinamento.

There could be more than one tree that fits the same data! The induced tree is algorithm-dependent



Árvores de Decisão (testando um exemplo)

Start from the root of tree.




Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

Partindo de uma AD criada, pode-se testar a árvore com os dados de teste e calcular sua acurácia (precisão).




Árvores de Decisão (testando um exemplo)





Árvores de Decisão (representação)



○ Representação:

- Cada **nó** de decisão contem um teste num atributo
- Cada **ramo** descendente corresponde a um possível valor deste atributo
- Cada **folha** está associada a uma classe
- Cada **percurso** na árvore (da raiz à folha) corresponde a uma regra de classificação



Árvores de Decisão (Construção)

Passos:

- ♦ 1. Escolher um atributo.
- ♦ 2. Estender a árvore adicionando um ramo para cada valor do atributo.
- ♦ 3. Passar os exemplos para as folhas (tendo em conta o valor do atributo escolhido)
- ♦ 4. Para cada folha
 - 1. Se todos os exemplos são da mesma classe, associar essa classe à folha
 - 2. Senão repetir os passos 1 a 4.
- ♦ Questão: qual atributo escolher para dividir os exemplos?



Árvores de Decisão (Construção)

Escolha do atributo:

- ◆ Como medir a habilidade de um dado atributo discriminar as classes?
- ◆ Existem várias medidas que podem ser aplicadas
- ◆ Todas concordam em dois pontos:
 - Uma divisão que mantém as proporções de classes em todas as partições é inútil
 - Uma divisão em que cada partição conterá todos os exemplos de uma mesma classe tem utilidade máxima
- ◆ Queremos sempre encontrar a menor árvore possível (menor profundidade)



Árvores de Decisão (Algoritmo)

Regra de Decisão: algoritmo ID3

- ♦ Encontra-se, a cada passo, a melhor divisão possível.
- ♦ Calcula-se o valor do ganho de divisão, usando as informações abaixo:
 - 1) Entropia do sistema
 - 2) Entropia do sistema com a divisão
 - 3) Ganho de entropia com a divisão

Condições de parada do particionamento

- ♦ Todos os exemplos de um dado nó pertence a mesma classe.
- ♦ Não existem mais atributos para particionamento



Árvores de Decisão (Algoritmo)

Cálculo da Entropia do Sistema

- ♦ A entropia do sistema representa o quanto de informação um conjunto de dados carrega.
- ♦ Mede o grau de “impureza” (desordem)
 - Se entropia = 0, o conjunto é “puro”.
 - Se entropia = 1, o conjunto é totalmente “impuro”.
- ♦ Para problemas com duas classes, tipo: Sim e Não
 - Se um conjunto tiver apenas exemplos da classe **Sim** ou da classe **Não**, a sua entropia será **0**.
 - Se um conjunto contiver o mesmo número de exemplos da classe **Sim** e da classe **Não**, a sua entropia será **1**.



Árvores de Decisão (Algoritmo)

Cálculo da Entropia do Sistema:

$$E = - \sum_{i=1}^m p_i \log_2(p_i)$$

Cálculo da Entropia do Sistema com a divisão:

- ♦ Divide-se o banco de dados no número de classes do atributo.
- ♦ Calcula-se E de cada atributo (E1, E2, E3, EN)

$$E(\text{divisão}) = \sum_{i=1}^n p_{E_i} (E_i)$$



Árvores de Decisão (Algoritmo)

Cálculo do Ganho de Entropia com a divisão do Sistema:

- ♦ O ganho de entropia pode ser calculado subtraindo a entropia do sistema da entropia com a divisão.
- ♦ O ganho é calculado para todos os atributos possíveis, elegendo-se o maior.

$$\text{Ganho} = E - E(\text{divisão})$$



Árvores de Decisão (Exemplo 1)

- ◆ Agora vamos detalhar qual atributo é o mais apropriado para ser utilizado no particionamento das amostras do exemplo do problema do tempo.
- ◆ Vamos utilizar como exemplo o banco de dados sobre condições meteorológicas.
- ◆ O objetivo é identificar quais as condições ideais para se jogar um determinado jogo.



Árvores de Decisão (Exemplo 1)

Estado	Temp	Umid	Vento	Jogo
ensolarado	quente	alta	falso	não
ensolarado	quente	alta	verdade	não
nublado	quente	alta	falso	sim
chuvoso	amena	alta	falso	sim
chuvoso	fria	normal	falso	sim
chuvoso	fria	normal	verdade	não
nublado	fria	normal	verdade	sim
ensolarado	amena	alta	falso	não
ensolarado	fria	normal	falso	sim
chuvoso	amena	normal	falso	sim
ensolarado	amena	normal	verdade	sim
nublado	amena	alta	verdade	sim
nublado	quente	normal	falso	sim
chuvoso	amena	alta	verdade	não




Árvores de Decisão (Exemplo 1)

- ♦♦ Considere as quatro possibilidades para a escolha do atributo que será utilizado para dividir o conjunto de dados no primeiro nível da árvore.




Árvores de Decisão (Exemplo 1)

Estado	Temp	Umid	Vento	Jogo
ensolarado	quente	alta	falso	não
ensolarado	quente	alta	verdade	não
nublado	quente	alta	falso	sim
chuvoso	amena	alta	falso	sim
chuvoso	fria	normal	falso	sim
chuvoso	fria	normal	verdade	não
nublado	fria	normal	verdade	sim
ensolarado	amena	alta	falso	não
ensolarado	fria	normal	falso	sim
chuvoso	amena	normal	falso	sim
ensolarado	amena	normal	verdade	sim
nublado	amena	alta	verdade	sim
nublado	quente	normal	falso	sim
chuvoso	amena	alta	verdade	não



?





Árvores de Decisão (Exemplo 1)

- ♦ Defina uma função *Info* que calcula o grau de pureza de um atributo num determinado nó.
- ♦ Este grau de pureza representa a quantidade de informação esperada que seria necessária para especificar se uma nova instância seria classificada em 'Sim' ou 'Não', uma vez chegado a este nó.
- ♦ Entropia do sistema com divisão:

$$Info(nó) = \sum_i \frac{n_i}{N} Entropia(A_i)$$

- ♦ Quanto maior a entropia, maior a informação. A entropia é uma medida estatística que mede o quão confuso é a distribuição das instâncias entre as classes.



Árvores de Decisão (Exemplo 1)

- ♦ Se escolhermos o atributo estado:

$$\text{Info(estudo)} = \frac{5}{14} \text{Entropia(ensolarado)} + \frac{4}{14} \text{Entropia(nublado)} + \frac{5}{14} \text{Entropia(chuvoso)}$$

- ♦ $\text{Entropia(ensolarado)} = \frac{2}{5} \log_2 \frac{2}{5} + \frac{3}{5} \log_2 \frac{3}{5} = 0.971$

- ♦ $\text{Entropia(nublado)} = \frac{4}{4} \log_2 \frac{4}{4} + \frac{0}{4} \log_2 \frac{0}{4} = 0$

- ♦ $\text{Entropia(chuvoso)} = \frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5} = 0.971$

Logo:

- ♦ $\text{Info(estudo)} = \frac{5}{14} * 0.971 + \frac{4}{14} * 0 + \frac{5}{14} * 0.971 = 0.693$



Árvores de Decisão (Exemplo 1)

- ♦ Se escolhermos o atributo temperatura:

$$\text{Info(temp)} = \frac{4}{14} \text{Entropia(quente)} + \frac{4}{14} \text{Entropia(frio)} + \frac{6}{14} \text{Entropia(amen)} = 0.911$$

- ♦ Se escolhermos o atributo umidade:

$$\text{Info(umi)} = \frac{7}{14} \text{Entropia(alta)} + \frac{7}{14} \text{Entropia(normal)} = 0.788$$

- ♦ Se escolhermos o atributo vento:

$$\text{Info(vento)} = \frac{6}{14} \text{Entropia(verdade)} + \frac{8}{14} \text{Entropia(falso)} = 0.892$$



Árvores de Decisão (Exemplo 1)

Ganho de Entropia (informação):

- ◆ Ganho de informação ao escolher um atributo:
 - O ganho de informação ao escolher um atributo A como um nó é a diferença entre a informação associada ao nó antes (info-pré) da divisão e a informação associada ao nó após a divisão (info-pós).



Árvores de Decisão (Exemplo 1)

Ganho de Entropia (informação):

♦ No exemplo em questão temos que

$$\text{info-pré} = 9/14 \log_2 9/14 + 5/14 \log_2 5/14 = 0.940$$

♦ Logo, os ganhos de informação de cada uma das quatro escolhas são:

$$\text{♦ Ganho (estado)} = 0.940 - 0.693 = 0.247$$

$$\text{♦ Ganho (temperatura)} = 0.940 - 0.911 = 0.029$$

$$\text{♦ Ganho (umidade)} = 0.940 - 0.788 = 0.152$$


$$\text{♦ Ganho (vento)} = 0.940 - 0.892 = 0.048$$

♦ O atributo ideal para dividir as amostras é o atributo **estado**



Árvore de Decisão (Exemplo 1)

Estado	Temp	Umid	Vento	Jogo
ensolarado	quente	alta	falso	não
ensolarado	quente	alta	verdade	não
nublado	quente	alta	falso	sim
chuvoso	amena	alta	falso	sim
chuvoso	fria	normal	falso	sim
chuvoso	fria	normal	verdade	não
nublado	fria	normal	verdade	sim
ensolarado	amena	alta	falso	não
ensolarado	fria	normal	falso	sim
chuvoso	amena	normal	falso	sim
ensolarado	amena	normal	verdade	sim
nublado	amena	alta	verdade	sim
nublado	quente	normal	falso	sim
chuvoso	amena	alta	verdade	não



folha

Que atributos utilizar?




Árvores de Decisão (Exemplo 1)

Após a escolha do nó raiz, o processo continua recursivamente:

- ◆ No exemplo em questão iremos testar a utilização dos atributos restantes nos nós não folhas. Novamente a escolha será feita através do cálculo da Entropia e do Ganho de Entropia.
- ◆ Escolhe-se outro atributo para particionar os ramos ensolarado e chuvoso
 - O ramo nublado não precisa ser particionado, pois todos os exemplos do ramo pertencem à mesma classe (nó folha).



Árvores de Decisão (Exemplo 1)





Árvores de Decisão (Exemplo 1)

Estado	Temp	Umid	Vento	Jogo
ensolarado	quente	alta	falso	não
ensolarado	quente	alta	verdade	não
nublado	quente	alta	falso	sim
chuvoso	amena	alta	falso	sim
chuvoso	fria	normal	falso	sim
chuvoso	fria	normal	verdade	não
nublado	fria	normal	verdade	sim
ensolarado	amena	alta	falso	não
ensolarado	fria	normal	falso	sim
chuvoso	amena	normal	falso	sim
ensolarado	amena	normal	verdade	sim
nublado	amena	alta	verdade	sim
nublado	quente	normal	falso	sim
chuvoso	amena	alta	verdade	não




Árvores de Decisão (Exemplo 1)

- ♦ Logo, os ganhos de informação de cada uma das três escolhas são:
- ♦ $\text{Ganho (temperatura)} = 0.971 - (2/5)0.0 - (2/5)1.0 - (1/5)0.0 = 0.571$
- ♦ $\text{Ganho (umidade)} = 0.971 - (3/5)0.0 - (2/5)0.0 = 0.971$
- ♦ $\text{Ganho (vento)} = 0.971 - (2/5)1.0 - (3/5)0.918 = 0.020$
- ♦ O atributo ideal para dividir as amostras é o atributo **umidade**.



Árvores de Decisão (Exemplo 1)



folhas

Que atributos utilizar?



Problemática

- ◆ Problema em atributos com grande ordem de classes
- ◆ Convergência para “pureza” é maior com um aumento no número de classes
 - Ganho de informação é tendencioso na escolha de atributos com muitos estados
 - Pode resultar na escolha de atributos sub-ótimos



Gain ratio

- ◆ Reduz o bias em atributos com muitos ramos
- ◆ Leva em consideração o número de ramos ao pontuar o atributo
 - Maior em dados bem espaçados
 - Menor quando todos pertencem a um único ramo


$$\text{gain_ratio}(\text{"Atributo"}) = \frac{\text{gain}(\text{"Atributo"})}{\text{intrinsic_info}(\text{"Atributo"})}$$

↓
Entropia("Atributo")



Random Forest


- ◆ Amostragem aleatória ('random')
- ◆ Treinamento de várias árvores individuais ('forest')





Random Forest

- Combinação da simplicidade das árvores de decisão com a flexibilidade e aleatoriedade para melhorar a precisão.
- Combinam muitas árvores para prever o melhor resultado.
- Aleatoriedade na seleção de atributos.
- Cada árvore é consultada e o resultado final é o que ocorrer com maior frequência.






Random Forest

- Resumindo:


- Criação do Bootstrapped Dataset.(n amostras do conjunto tota N)
- A cada passo é selecionado um número m de features para montar a árvore.($m < M$)
- Diversas árvores são criadas a partir de subconjuntos diferentes.
- A instância de teste deve percorrer cada árvore da floresta e a classe definida será a mais votada ou a médias das respostas no caso do uso para regressão.





Random Forest

- Vantagens:
 - Maior robustez. Eficiência no uso de um conjunto de árvores.
 - Menos propenso a sofrer overfitting em comparação com uma única árvore de decisão.
- Desvantagens:
 - Exige uma maior poder de processamento para o treino ou criação das arvores.
 - Pode ser lento o processo de classificação de novas amostras dependendo da quantidade de dados.
 - Eficiente na classificação mas não bom desempenho na regressão.





◆◆Dúvidas???



Tarefas

1. Complete a árvore escolhendo entre os atributos Ventania e Temperatura