




Inferência Bayesiana

Prof. Jasmine Araújo
jasmine@ufpa.br

Inferência estatística

- ♦ Obter conclusões sobre algumas características de um conjunto de interesse, denominado população, com base na informação oriunda de um conjunto de dados disponíveis, denominado amostra





Probabilidade

◆ Probabilidade

- Modela o grau de crença de um agente
- Dado evidências disponíveis

A probabilidade proporciona um meio para resumir a incerteza que vem de nossa:

- falta de vontade/motivação: falha em numerar todas as exceções, antecedentes ou consequentes para assegurar uma regra sem exceções
- ignorância: falta de conhecimento sobre fatos relevantes, condições iniciais, etc.



Probabilidade

- ◆ Regra do Produto: probabilidade $P(AB)$ da conjunção de dois eventos A e B :

$$P(A, B) = P(A | B)P(B) = P(B | A)P(A)$$

- ◆ Regra da Soma: probabilidade da disjunção de dois eventos A e B :

$$P(A + B) = P(A) + P(B) - P(AB)$$



- ◆ Teorema da probabilidade total

$$\sum_{i=1}^n P(A_i) = 1, \text{ then } P(B) = \sum_{i=1}^n P(B | A_i)P(A_i)$$

Probabilidade

◆ Teorema da probabilidade total

$$\sum_{i=1}^n P(A_i) = 1, \text{ then } P(B) = \sum_{i=1}^n P(B | A_i)P(A_i)$$





Probabilidade

♦ Teorema da probabilidade total

Exemplo:

O governo acredita que, este ano, a probabilidade da inflação ficar abaixo de 2% é de 0.20; entre 2% e 3% é de 0.45 e acima de 3% é de 0.35.

Admite-se que se a inflação ficar abaixo de 2% a probabilidade de se criar 100000 empregos é de 0.60 diminuindo para 0.30 caso a inflação fique entre 2% e 3% com uma inflação acima de 3% é totalmente impossível atingir aquele objetivo. Qual é a probabilidade de se criarem 100000 empregos este ano?



Probabilidade

♦ Teorema da probabilidade total

Exemplo:

A1= inflação abaixo de 2%

A2=inflação entre 2% e 3%

A3=inflação acima de 3%

B=criar 100000 empregos



$$P(A1)=0.2 \quad P(A2)=0.45 \quad P(A3)=0.35$$

$$P(B|A1)=0.6 \quad P(B|A2)=0.30 \quad P(B|A3)=0$$

$$\text{LOGO: } P(B) = P(A1)*P(B|A1) + P(A2)*P(B|A2) + P(A3)*P(B|A3) = 0.2*0.6 + 0.45*0.3 + 0.35*0 = 0.255$$



Probabilidade

- ◆ Associa às sentenças um grau de crença numérico entre 0 e 1
 - Contudo, cada sentença ou é **verdadeira** ou é **falsa**
- ◆ Grau de crença(probabilidade):
 - a priori(incondicional): calculado antes do agente receber percepções
 - Ex. $P(\text{cárie} = \text{true}) = P(\text{cárie}) = 0.5$
 - condicional: calculado de acordo com as **evidências** disponíveis
 - **evidências**: percepções que o agente recebeu até agora
 - Ex: $P(\text{cárie} | \text{dor de dente}) = 0.8$
 $P(\text{cárie} | \sim \text{dor de dente}) = 0.3$



Probabilidade condicional

- ◆◆ Probabilidade condicional (a posteriori) de A dado que B ocorreu é definida por:
 - $P(A|B) = \frac{P(A \wedge B)}{P(B)}$, quando $P(B) > 0$.

- ◆◆ Probabilidade condicional:
 - possibilita inferência sobre uma proposição desconhecida A dada a evidência B



Probabilidade Condicional e Independência

♦♦ Independência:

- $P(A|B) = P(A)$
- Exemplo: A = dor de dente e B=úlceras
 - Úlceras não causa dor de dente

♦♦ Eventos mutuamente excludentes

- $P(A \wedge B) = 0$
- Experimento: Lançamento de um dado
 - A = a face do dado é ímpar e B = a face do dado é par

♦♦ Independência condicional

- Seja X e Y independentes dado Z $\Rightarrow P(X|Y,Z) = P(X|Z)$



Independência Condicional

◆ $P(X|Y,Z) = P(X|Z)$

■ Isso quer dizer que se o objetivo é saber a probabilidade de X , então não importa o valor de Y se você já sabe o valor de Z

◆ **Exemplo: Trovão é condicionalmente independente de Chuva, dado Relâmpago**

■ $P(\text{Trovão/ Chuva, Relâmpago}) = P(\text{Trovão/ Relâmpago})$



Aprendizagem Bayesiana

- ◆ Fornece probabilidades para suas respostas.
- ◆ Permite combinar facilmente conhecimento a priori com dados de observação.
 - Rede Bayesiana Ingênua (*Naïve Bayesian Network*)
 - Rede Bayesiana de Crença (*Bayesian Belief Network*)



Teorema de Bayes

- ♦♦ Calcula a probabilidade de diferentes hipóteses à medida que novas evidências são observadas.

- Seja h : hipótese e D : evidência

- Objetivo: Calcular $P(h|D)$

$$P(h | D) = \frac{P(D | h)P(h)}{P(D)}$$

- ♦♦ $P(h)$: probabilidade à priori de h
- ♦♦ $P(D)$: probabilidade à priori de D
- ♦♦ $P(D|h)$: probabilidade de observar D dado que h aconteceu



Teorema de Bayes

Exemplo:

Uma fábrica tem três máquinas A1, A2 e A3 que correspondem, respectivamente a 40%, 35% e 25% da sua produção. A proporção de peças defeituosas na máquina A1 é de 2%. De 1% para a máquina A2 e de 3% para a máquina A3

Escolhendo-se uma peça ao acaso verificou-se que era defeituosa. Qual a probabilidade De ser produzida pela máquina A1?

Resolução: $P(A1)=0.4$ $P(A2)=0.35$ e $P(A3)=0.25$

$P(B|A1)=0.02$ $P(B|A2)=0.01$ $P(B|A3)=0.03$

O pedido é:

$$P(A1|B) = \frac{P(B \cap A1)}{P(B)} = \frac{P(A1) \cdot P(B|A1)}{(P(A1) \cdot P(B|A1) + P(A2) \cdot P(B|A2) + P(A3) \cdot P(B|A3))} = \frac{(0.40 \cdot 0.02)}{(0.40 \cdot 0.02 + 0.35 \cdot 0.01 + 0.25 \cdot 0.03)} = 0.42$$



Teorema de Bayes

Exemplo:

Qual é a probabilidade de dadas 2 garotas ao menos 1 ser mulher?

GG GH HG HH

$$P(GG)=1/4$$

$$P(1G)=3/4$$

$$P(1G/GG)=1$$

$$\text{Resolução: } P(1G)=3/4 \quad P(GG)=1/4$$

$$P(1G|GG)=1$$

$$P(GG/1G)=P(1G/GG) \times P(GG) / (P(1G)) = (1 \times 1/4) / (3/4) = 0.33$$



Algoritmos baseados no Teorema de Bayes ou métodos probabilísticos Bayesianos.

- ▶ São formas de trabalhar com tarefas preditivas em aprendizado de máquina, principalmente quando as informações disponíveis são incompletas ou imprecisas.

Resumo dos conceitos de probabilidade e do Teorema de Bayes:



Algoritmos baseados no Teorema de Bayes ou métodos probabilísticos Bayesianos.

Lei da probabilidade total:

$$P(A) = \sum P(A|B_i) \times P(B_i)$$

Lei da probabilidade condicional

$$P(A|B) = P(A \cap B) / P(B)$$

e o Teorema de Bayes:

$$P(A \cap B) = P(B \cap A) \Rightarrow P(A|B) \times P(B) = P(B|A) \times P(A) \Rightarrow$$

$$P(A|B) = P(B|A) \times P(A) / P(B)$$



Aprendizado Bayesiano - exemplo

► Considere o seguinte cenário:

Vamos supor que a probabilidade de observar alguém com uma dada doença é de 8%.


E que existe um teste para o diagnóstico dessa doença, cujo resultado possui um grau de incerteza. Sabe-se que em 75% dos casos em que o resultado do teste foi positivo a doença foi confirmada e que em 96% em que o resultado do teste foi negativo o paciente não tinha a doença.

Representação da doença como uma variável aleatória com dois possíveis valores: presente e ausente. O resultado do teste também tem dois possíveis valores alternativos: positivo ou negativo.

É possível observar que o valor Doença influencia o valor do Teste, mas o oposto não é verdade. Representação em forma de grafo:




Aprendizado Bayesiano - exemplo



No grafo estão os nós representam as variáveis ou atributos e a aresta direcionada representa a influência entre variáveis.



Aprendizado Bayesiano - exemplo



No grafo estão os nós representam as variáveis ou atributos e a aresta direcionada representa a influência entre variáveis.


A informação gráfica é qualitativa – quem influencia quem, neste caso Doença influencia Teste .

Há também uma informação quantitativa – a probabilidade a priori de observar a doença:

$$P(\text{Doença} = \text{presente}) = 0,08 \text{ e } P(\text{Doença} = \text{ausente}) = 0,92$$



Aprendizado Bayesiano - exemplo




A partir de experiências passadas da utilização do teste, é possível inferir as probabilidades condicionais para a variável Teste:

$$P(\text{Teste} = \text{positivo} \mid \text{Doença} = \text{presente}) = 0,75$$

$$P(\text{Teste} = \text{negativo} \mid \text{Doença} = \text{ausente}) = 0,96$$



Aprendizado Bayesiano - exemplo



Essa informação é definida nos nós do modelo gráfico acima.

Este modelo probabilístico gráfico é composto pelo modelo qualitativo e modelo quantitativo.


Resumindo:

Modelo qualitativo: um grafo cujos nós representam as variáveis.

Modelo Quantitativo: tabela com a distribuição das variáveis.



Aprendizado Bayesiano - exemplo



Qual é o poder preditivo do Teste com respeito à Doença?

Calculando as probabilidades a priori para a variável Teste e considerando que:


$P(A) = \sum P(A | B_i) \times P(B_i)$ teorema da probabilidade total e que B é a Doença que tem 2 estados: presente e ausente, então:

$P(\text{Teste}=\text{positivo}) = P(\text{Teste}=\text{positivo} | \text{Doença}=\text{presente}) \times P(\text{Doença}=\text{presente}) +$

$P(\text{Teste}=\text{positivo} | \text{Doença}=\text{ausente}) \times P(\text{Doença}=\text{ausente}) = 0,75 \times 0,08 + 0,04 \times 0,92 = 0,0968$



Aprendizado Bayesiano - exemplo




$$P(\text{Teste}=\text{positivo}) = P(\text{Teste}=\text{positivo} \mid \text{Doença}=\text{presente}) \times P(\text{Doença}=\text{presente}) + P(\text{Teste}=\text{positivo} \mid \text{Doença}=\text{ausente}) \times P(\text{Doença}=\text{ausente}) = 0,75 \times 0,08 + 0,04 \times 0,92 = 0,0968$$

$$P(\text{Teste}=\text{negativo}) = P(\text{Teste}=\text{negativo} \mid \text{Doença}=\text{presente}) \times P(\text{Doença}=\text{presente}) + P(\text{Teste}=\text{negativo} \mid \text{Doença}=\text{ausente}) \times P(\text{Doença}=\text{ausente}) = 0,25 \times 0,08 + 0,96 \times 0,92 = 0,9032$$



Aprendizado Bayesiano - exemplo



Se um dado paciente o resultado do Teste for positivo, podemos concluir que ele está doente?


No aprendizado bayesiano, o valor de uma variável aleatória tem uma probabilidade associada.

A questão é:

Qual é a probabilidade $P(\text{Doença} = \text{presente} | \text{Teste} = \text{positivo})$?



Aprendizado Bayesiano - exemplo



Qual é a probabilidade $P(\text{Doença} = \text{presente} \mid \text{Teste} = \text{positivo})$?

$P(\text{Doença} = \text{presente} \mid \text{Teste} = \text{positivo}) =$

$(P(\text{Teste} = \text{positivo} \mid \text{Doença} = \text{presente}) * P(\text{Doença} = \text{presente})) / P(\text{Teste} = \text{positivo}) =$
 $0,75 * 0,08 / 0,0968 = 0,6198$ ou 61,98%

Qual é a probabilidade $P(\text{Doença} = \text{presente} \mid \text{Teste} = \text{negativo})$?

$P(\text{Doença} = \text{presente} \mid \text{Teste} = \text{negativo}) =$

$(P(\text{Teste} = \text{negativo} \mid \text{Doença} = \text{presente}) * P(\text{Doença} = \text{presente})) / P(\text{Teste} = \text{negativo}) =$
 $0,25 * 0,08 / 0,9032 = 0,0221$ ou 2,21%




Outro exemplo:

1. Uma caixa contém duas bolas vermelhas e três bolas azuis. Duas bolas são retiradas ao acaso, uma em seguida da outra e sem que a primeira tenha sido recolocada.

- a) Qual é a probabilidade de a **segunda** (evento B) bola retirada ser vermelha sob a condição de a **primeira** (evento A) bola retirada ser azul?
- b) Qual é a probabilidade de a **primeira** (evento A) bola retirada ser a azul sob a condição de a **segunda** (evento B) ser vermelha?



Uma caixa contém duas bolas vermelhas e três bolas azuis. Duas bolas são retiradas ao acaso, uma em seguida da outra e sem que a primeira tenha sido recolocada.





- a) Qual é a probabilidade de a segunda (evento B) bola retirada ser vermelha sob a condição de a primeira (evento A) bola retirada ser azul?
- b) Qual é a probabilidade de a primeira (evento A) bola retirada ser a azul sob a condição de a segunda (evento B) ser vermelha?

A primeira questão pede uma **probabilidade condicional**:

$$P(B|A) = P(A \cap B) / P(A)$$

$$P(\text{vermelha}|\text{azul}) = P(\text{azul} \cap \text{vermelha}) / P(\text{azul}) = \\ (3/10) / (3/5) = 1/2$$



- a) Qual é a probabilidade de a segunda (evento B) bola retirada ser vermelha sob a condição de a primeira (evento A) bola retirada ser azul?
- b) Qual é a probabilidade de a primeira (evento A) bola retirada ser a azul sob a condição de a segunda (evento B) ser vermelha?

A segunda questão deve ser tratada pelo **teorema de Bayes**:

$$P(A|B)=P(B|A)P(A)/P(B)$$

$$P(B)=P(B|A)P(A)+P(B|\sim A)P(\sim A)$$

$$P(\text{azul}|\text{vermelha})=P(\text{azul} \cap \text{vermelha})/(P(\text{azul} \cap \text{vermelha})+P(\text{vermelha} \cap \text{vermelha}))$$

$$P(\text{azul}|\text{vermelha})=3/10/(3/10+1/10)=3/4$$



Outro exemplo:

2. A probabilidade de diagnosticar corretamente determinada doença rara é 0,70. Quando diagnosticada corretamente, a probabilidade de cura é 0,90. Se não for diagnosticada corretamente, a probabilidade de cura é 0,40. Se o paciente com a doença é curado, qual é a probabilidade de que tenha sido diagnosticado corretamente?



Outro exemplo:

2. A probabilidade de diagnosticar corretamente determinada doença rara é 0,70. Quando diagnosticada corretamente, a probabilidade de cura é 0,90. Se não for diagnosticada corretamente, a probabilidade de cura é 0,40. Se o paciente com a doença é **curado**, qual é a probabilidade de que tenha sido diagnosticado corretamente?

D- diagnóstico correto

C- cura

$$P(D)=0,7 \quad P(\sim D)=0,3$$

$$P(C|D)=0,9 \quad P(C|\sim D)=0,4$$


$$P(D|C)=P(C|D)P(D)/P(C)$$

$$P(C) = P(C|D)P(D) + P(C|\sim D)P(\sim D) = (0,9*0,7 + 0,4*0,3)$$

$$P(D|C) = (0,9*0,7)/(0,9*0,7 + 0,4*0,3) = 0,84$$



Aplicações:






Aplicações: Predição do tempo

Diagram illustrating the components of the Bayesian formula for weather prediction:

- Likelihood** points to $P(\text{cloud}|\text{rain})$
- Prior** points to $P(\text{rain})$
- Evidence** points to $P(\text{cloud})$
- Posterior** points to $P(\text{rain}|\text{cloud})$

$$P(\text{rain}|\text{cloud}) = \frac{P(\text{cloud}|\text{rain}) P(\text{rain})}{P(\text{cloud})}$$

Aplicações:






Resumo da Representação do Teorema de Bayes:

Os dados, estão na forma de sintomas, e são usados para encontrar uma probabilidade/verossimilhança, o qual é a probabilidade desses sintomas dado que o paciente tem uma doença específica.

O teorema de Bayes combina essa verossimilhança com conhecimento a priori, e e dá como resultado a probabilidade posterior de que o paciente tenha a doença, visto que ele tem os sintomas observados.





O problema de Inferência e o Teorema de Bayes

Suponha que $P(y_i|x)$ denota a probabilidade de um exemplo x pertencer a classe y_i .

A função de custo, que representa o custo de associar x à classe incorreta, é minimizada se, e somente se, x é associado à classe y_k para a qual $P(y_k|x)$ é máxima.



O problema de Inferência e o Teorema de Bayes

Esse método é designado por estimativa MAP – Maximum A Posteriori.

Formalmente, a classe que deve ser associada ao exemplo x é dada por:

$$y_{\text{map}} = \underset{i}{\operatorname{argmax}} P(y_i | x)$$

No qual $\underset{i}{\operatorname{argmax}}$ retorna a classe y_i com maior probabilidade de estar associada a x , que é aquela que possui o valor máximo para $P(y_i | x)$



O problema de Inferência e o Teorema de Bayes

Qualquer função que calcula as probabilidades condicionais é chamada de função discriminante (por separar exemplos de classes diferentes).

- Dado um exemplo x , o teorema de Bayes provê um método para calcular $P(y_i | x)$:

- $P(y_i | x) = P(y_i)P(x | y_i) / P(x)$

- A hipótese que maximiza $P(\text{dados} | \text{hipótese})$ é designada por máxima verossimilhança:

- $h_{mv} = \arg\max_i P(x | y_i)$




Maximum-Likelihood Estimation- MLE

O método busca aqueles valores para os parâmetros de maneira a maximizar a probabilidade dos dados amostrados, dado o modelo assumido.



Naïve Bayes


- ▶ Atributos independentes entre si, mas dependentes de um atributo principal





Naïve Bayes

- ▶ Atributos independentes entre si, mas dependentes de um atributo principal



Dada a classe $P(x|y_i)$ pode ser decomposto em no produto: $P(x_1|y_i) \times P(x_2|y_i) \times \dots \times P(x_d|y_i)$



Naïve Bayes

- ▶ Dada a classe $P(x|y_i)$ pode ser decomposto em no produto: $P(x_1|y_i) * \dots * P(x_d|y_i)$

A probabilidade de um exemplo pertencer a classe y_i é proporcional à expressão:

$$P(y_i|x) \propto P(y_i) \prod_{j=1}^d P(x_j|y_i)$$



Naïve Bayes

- ▶ O classificador obtido pelo uso da função discriminante :

$$P(y_i|x) \propto P(y_i) \prod_{j=1}^d P(x_j|y_i)$$

E pela regra de decisão:

$$y_{\text{map}} = \arg\max_i P(y_i | x)$$

É conhecido como Naive Bayes.



Resumindo: Escolha das Hipóteses

- ◆ Geralmente, existe um espaço de hipóteses (H), e deseja-se a hipótese ($h \in H$) mais provável, observados os dados de treino (D)
- ◆ Hipótese de máxima a posteriori h_{MAP}

$$\begin{aligned} h_{\text{MAP}} &= \arg \max_{h \in H} P(h / D) \\ &= \arg \max_{h \in H} \frac{P(D / h) P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(D / h) P(h) \end{aligned}$$

- ◆ Hipótese de máxima verossimilhança h_{ML} (supondo que $P(h_i) = P(h_j)$)

$$h_{\text{ML}} = \arg \max_{h_i \in H} P(D / h_i)$$



Resumo: Classificador Naive Bayes

$$P(a_i | v_1, v_2, \dots, v_n) = P(a_i) \prod_{j=1}^{n_v} P(v_j | a_i)$$

Classificador Naive Bayes:

$$a_{NB} = \operatorname{argmax}_{a_i \in V} P(a_i) \prod_{j=1} P(v_j | a_i)$$



Resumo: Classificador Naive Bayes

- Em resumo, o algoritmo Naive Bayes envolve:
 - Aprendizagem no qual os termos $P(a_i)$ e $P(v_j|a_i)$ são estimados baseado nas suas frequências no conjunto de treinamento.
 - O conjunto destas estimativas corresponde as hipóteses aprendidas
 - As hipóteses são então utilizadas para classificar cada nova instância aplicando a equação vista anteriormente (a_{NB})



Classificador Naive Bayes

Exemplo

Exemplo:

Considere os 14 exemplos de treinamento de PlayTennis e uma nova instância que o Naive Bayes deve classificar:

<Outlook=sunny, Temperature=cool, Humidity=high,
Wind=strong>

Nossa tarefa é predizer o valor alvo (yes ou no) do conceito Play Tennis para esta nova instância



Classificador Naive Bayes

Exemplo

Atributo alvo: *PlayTennis* (yes, no)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No



Classificador Naïve Bayes

Exemplo

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

Exemplo:

O valor alvo será dado por a_{NB} :

$$a_{NB} = \operatorname{argmax}_{a_i \in V} P(a_i) \prod_{j=1} P(v_j | a_i)$$

$$= \operatorname{argmax} P(a_j) P(\text{Outlook=sunny} | a_j) P(\text{Temperature=cool} | a_j) P(\text{humidity=high} | a_j) P(\text{Wind=strong} | a_j)$$

Para calcular v_j foi instanciado utilizando os valores particulares de atributo da nova Instância.

Para calcular a_{NB} são necessárias 10 probabilidades que podem ser estimadas a partir dos exemplos de treinamento.



Classificador Naive Bayes

Exemplo

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

Atributo alvo: **PlayTennis (yes, no)**

Exemplo:

O valor alvo será dado por a_{NB} :

$$a_{NB} = \operatorname{argmax}_{a_i \in V} P(a_i) \prod_{j=1} P(v_j | a_i)$$

Probabilidades a priori:

$$P(\text{PlayTennis=yes}) = 9/14 = 0.64$$

$$P(\text{PlayTennis=no}) = 5/14 = 0.36$$

Probabilidades Condicionais:

$$P(\text{Wind=strong} | \text{PlayTennis=yes}) = 3/9 = 0.3$$

$$P(\text{Wind=strong} | \text{PlayTennis=no}) = 3/5 = 0.6$$

$$P(\text{Humidity=high} | \text{PlayTennis=yes}) = 3/9 = 0.33$$

$$P(\text{Humidity=high} | \text{PlayTennis=no}) = 4/5 = 0.8$$

$$P(\text{Temperature=cool} | \text{PlayTennis=yes}) = 3/9 = 0.33$$

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Probabilidades Condicionais:

$$P(\text{Temperature=cool} | \text{PlayTennis=no}) = 1/5 = 0.2$$

$$P(\text{Outlook=sunny} | \text{PlayTennis=yes}) = 2/9 = 0.22$$

$$P(\text{Outlook=sunny} | \text{PlayTennis=no}) = 3/5 = 0.6$$



Classificador Naïve Bayes

Exemplo

Exemplo:

Usando estas estimativas de probabilidade e estimativas similares para os valores restantes dos atributos, calculamos a_{NB} de acordo com a equação anterior (omitindo nome dos atributos) :

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

$$P(\text{yes}) P(\text{sunny} | \text{yes}) P(\text{cool} | \text{yes}) P(\text{high} | \text{yes}) P(\text{strong} | \text{yes}) = 0.0053$$

$$P(\text{no}) P(\text{sunny} | \text{no}) P(\text{cool} | \text{no}) P(\text{high} | \text{no}) P(\text{strong} | \text{no}) = 0.026$$

Então o classificador atribui o valor alvo PlayTennis = no para esta nova instância.



Classificador Naive Bayes

Exemplo

Observação:

Suposição de independência condicional é muitas vezes violada . . . mas, de qualquer maneira, ele funciona bem. Note que não é necessário estimar probabilidades a posteriori $P'(a_j | v_j)$ para ser correta.



Classificador Naive Bayes

Exemplo

• Dia	Tempo	Temp.	Humid.	Vento	Jogar	
• D1	Sol	Quente	Alta	Fraco	Não	$P(\text{Sim}) = 5/10 = 0.5$
• D2	Sol	Quente	Alta	Forte	Não	$P(\text{Não}) = 5/10 = 0.5$
• D3	Coberto	Quente	Alta	Fraco	Sim	$P(\text{Sol/Sim}) = 1/5 = 0.2$
• D4	Chuva	Normal	Alta	Fraco	Sim	$P(\text{Sol/Não}) = 3/5 = 0.6$
• D5	Chuva	Frio	Normal	Fraco	Não	$P(\text{Frio/Sim}) = 2/5 = 0.4$
• D6	Chuva	Frio	Normal	Forte	Não	$P(\text{Frio/Não}) = 2/5 = 0.4$
• D7	Coberto	Frio	Normal	Forte	Sim	$P(\text{Alta/Sim}) = 2/5 = 0.4$
• D8	Sol	Normal	Alta	Fraco	Não	$P(\text{Alta/Não}) = 3/5 = 0.6$
• D9	Sol	Frio	Normal	Fraco	Sim	$P(\text{Forte/Sim}) = 1/5 = 0.2$
• D10	Chuva	Normal	Normal	Fraco	Sim	$P(\text{Forte/Não}) = 2/5 = 0.4$
						$P(\text{Sim})P(\text{Sol/Sim})P(\text{Frio/Sim})$
						$P(\text{Alta/Sim})P(\text{Forte/Sim}) =$
						$= 0.0032$
• D11	Sol	Frio	Alta	Forte	?	$P(\text{Não})P(\text{Sol/Não})P(\text{Frio/Não})$
						$P(\text{Alta/Não})P(\text{Forte/Não}) =$
						$= 0.0288$
						$\Rightarrow \text{Jogar (D11)} = \text{Não}$



Classificador Naive Bayes

Exemplo

Considere um problema de diagnóstico médico onde existem duas hipóteses alternativas:

1. O paciente tem câncer
2. O paciente não tem câncer

Os dados disponíveis são de um exame de laboratório com dois resultados possíveis:

- Positivo
- Negativo

Temos o conhecimento prévio que na população inteira somente 0.008 tem esta doença. O teste retorna um resultado positivo correto somente em 98% dos casos nos quais a doença está atualmente presente.

O teste retorna um resultado negativo correto somente em 97% dos casos nos quais a doença não esteja presente. Nos outros casos, o teste retorna o resultado oposto.



Classificador Naive Bayes

Exemplo

$$P(\text{câncer}) = 0.008$$

$$P(\neg\text{câncer}) = 0.992$$

$$P(\text{positivo} | \text{câncer}) = 0.98$$

$$P(\text{negativo} | \text{câncer}) = 0.02$$

$$P(\text{positivo} | \neg\text{câncer}) = 0.03$$

$$P(\text{negativo} | \neg\text{câncer}) = 0.97$$

Supondo que um paciente fez um teste de laboratório e o resultado deu positivo. O paciente tem câncer ou não ?

Calculando a hipótese com maior probabilidade a posteriori:

$$P(\text{positivo} | \text{câncer}) P(\text{câncer}) = 0.98 \cdot 0.008 = 0.0078$$

$$P(\text{positivo} | \neg\text{câncer}) P(\neg\text{câncer}) = 0.03 \cdot 0.992 = 0.0298$$

Assim, $h_{MAP} = \neg\text{câncer}$



Redes Bayesianas

- ◆ São modelos que denotam os relacionamentos probabilísticos entre as variáveis que representam um determinado domínio, possuindo:
 - Estrutura qualitativa: representando as dependências entre os nós
 - Estrutura quantitativa: tabelas de probabilidades condicionais dos nós, avaliando, em termos probabilísticos, as dependências



Redes Bayesianas

◆ Redes Bayesianas

- Representa os conhecimentos do domínio
 - Relações de dependência entre variáveis aleatórias
 - Probabilidades a priori das variáveis
 - Probabilidades condicionais entre variáveis dependentes
- Permite calcular eficientemente
 - Probabilidades a posteriori de qualquer variável aleatória (através de inferências) usando uma definição recursiva do teorema de Bayes



Redes Bayesianas

- ◆ Uma Rede Bayesiana, ou Rede Bayesiana de Crença (*Bayesian Belief Network*) é um grafo acíclico e dirigido onde:
 - Cada nó da rede representa uma variável aleatória
 - Um conjunto de ligações ou arcos dirigidos conectam os nós
 - Cada nó possui uma tabela de probabilidade condicional associada que quantifica os efeitos que os pais têm sobre o mesmo



Inferência Bayesiana

- ◆ É o procedimento geral para a construção de uma distribuição de probabilidades posteriores para os objetos de interesse dadas as probabilidades a priori
- ◆ Realizada através de cálculos probabilísticos
- ◆ Utiliza as informações existentes na Rede Bayesiana



Matemática da Inferência Bayesiana

◆ Regra de Bayes

$$P(A | B) = \frac{P(B \wedge A)}{P(B)} = \frac{P(B | A)P(A)}{P(B)}$$

ou

$$P(A | B) = \frac{P(B | A)P(A)}{P(B | A)P(A) + P(B | \bar{A})P(\bar{A})}$$




Matemática da Inferência Bayesiana

Generalizando temos

$$P(A = v_i \mid B) = \frac{P(B \mid A = v_i)P(A = v_i)}{\sum_{k=1}^{n_A} P(B \mid A = v_k)P(A = v_k)}$$



Exemplo Alarme





Exemplo Alarme (AIMA)

❖ Calcular a probabilidade do evento que o alarme toca mas não houve assalto nem terremoto e que João e Maria telefonaram.

$$\begin{aligned} & P(J \wedge M \wedge A \wedge \sim R \wedge \sim T) \\ &= P(J|A) P(M|A) P(A|\sim R \wedge \sim T) P(\sim R) P(\sim T) \\ &= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 \\ &= 0.00062 \text{ ou } 0.062 \% \end{aligned}$$




Aprendizagem da Estrutura de Redes Bayesianas

- ♦ **Métodos baseados em Busca e Pontuação** - pesquisa no espaço de possíveis estruturas
 - Determinar a melhor estrutura que se encaixa aos dados, iniciando com uma rede sem arcos e adicionando-os aos poucos e avaliando(pontuando) a estrutura obtida
 - Ex: K2(Cooper e Herskovits, 1992)
- ♦ **Métodos baseados em análise de dependência entre variáveis**
 - Iniciar com uma estrutura totalmente conectada com arcos sem direção, eliminar arcos baseando-se em testes de independência condicional
 - Ex: CBL(Chen, Bell e Liu 1997)




Saúde





Saúde





Considerações

◆ Redes Bayesianas tradicionais

- Permite representar mais fielmente a estrutura de um sistema
- Melhor visualização do comportamento dos atributos
- Permite representar e calcular as dependências entre os atributos

◆ Naive Bayes

- Simples e computacionalmente mais eficiente
- Robusto contra ruídos e dados irrelevantes
- Assume a independência entre os atributos



◆◆Dúvidas???

Introdução ao Weka:

[https://www.youtube.com/watch?v=Ev
cWffthAS0](https://www.youtube.com/watch?v=Ev
cWffthAS0)

Oficial da Universidade de Waikato:

<https://youtu.be/TF1yh5PKaqI>