



Inteligência Computacional

Prof. Jasmine Araújo
jasmine@ufpa.br

Baseados nos slides do Prof Ádamo Santana



Representação de Conhecimento

- ◆ Comumente um conjunto de sentenças em uma linguagem formal para descrever conhecimento.
- ◆ Uma boa representação torna explícitos os objetos a serem representados e as relações importantes entre esses objetos.
- ◆ Exemplos de representações
 - Lógica
 - Regras de Produção
 - . . .




Sistemas de Aprendizado

- ❖ As decisões são tomadas baseadas em experiências acumuladas contidas em casos resolvidos com sucesso
- ❖ Extrair conhecimento (regras) de um conjunto de dados de tal forma que estas regras possam ser aplicadas eficientemente a novos dados
- ❖ O aprendizado pode ser melhorado/adaptado a partir de novas interações (i.e. mais amostras)



Análise de Padrões





Aprendizado

- ◆ **Aprendizado supervisionado (classificação)**
 - **Supervisão:** Os dados de treinamento possuem rótulos indicando a classe da observação
 - **Novos dados são classificados baseados no conjunto de treino**
 - **Dado um conjunto de observações, no qual a classe é conhecida, o objetivo é tentar encontrar “regras” capazes de classificar novas observações entre as classes já existentes.**



Aprendizado

- ◆ Aprendizado não supervisionado (clustering)
 - O rótulo da classe do conjunto de treino é desconhecido
 - Dado um conjunto de observações, O objetivo é tentar estabelecer a existência de classes ou clusters nos dados



Classificação

- ❖ Função que mapeia objetos com características comuns, na mesma classe.
- ❖ Classifica dados (constrói modelos) baseados em um conjunto de treino e os valores (rótulos da classe) em um atributo de classificação utilizando-os na classificação de novos dados.



Classificação

- ❖ Dada uma coleção de instâncias (*conjunto de treinamento*)
 - Cada instância contém um conjunto de *atributos*, um dos atributos é a *classe - classificação supervisionada*
- ❖ A meta é induzir um *modelo* para o atributo classe como uma função de valores de outros atributos
- ❖ Objetivo: instâncias novas ou de previsão ou de execução devem ser classificadas tanto acuradamente quanto possível
 - Um *conjunto de teste* é usado para ajudar a estimar a acurácia de previsão (execução) do modelo



Classificação

(Etapas do Processo)

Construção do Modelo: descrevem um conjunto de classes predeterminadas

- ❖ Constituído de “regras” que permitem classificar as instâncias do banco de dados dentro de um número de classes pré-determinado.
- ❖ Criado a partir de um conjunto de dados de treinamento, cujos elementos são chamados de amostras ou Exemplos
- ❖ O modelo é representado como regras de classificação, árvores de decisão, fórmulas matemáticas, pesos de uma Rede Neural, etc...



Classificação (Etapas do Processo)


Modelo de uso: para classificar objetos desconhecidos ou futuros

◆ Estimar a exatidão do modelo:

- As “regras” são testadas sobre um conjunto de dados, completamente independente do conjunto de dados de treinamento, chamado de conjunto de teste
- Taxa de precisão é o percentual das amostras do conjunto de teste que são classificadas corretamente pelo modelo
- Conjunto de teste é independente do conjunto de treino, caso contrário poderá ocorrer overfitting (especialização do modelo)

Classificação

Buscar o melhor método para prever novas instâncias em classes préestabelecidas




**Regression,
Decision Trees,
Bayesian,
Neural Networks,
...**

**Especificado os pontos nas classes ● ●
A que classe pertence o ponto ○ ?**



Classificação: Regressão Linear




$$w_0 + w_1 x + w_2 y \geq 0$$

■ ■ Calcular w_i de modo a minimizar o erro médio quadrático




Classificação: Árvore de decisão



if $X > 5$ then blue
else if $Y > 3$ then blue
else if $X > 2$ then red
else blue

Classificação: Redes neurais



- **Consegue ajustar regiões mais complexas**
- **Pode sobreaprender os dados – achar padrões em ruídos**



Avaliação dos Métodos de Classificação

- ◆ Acurácia (precisão) na previsão das classes
- ◆ Velocidade e escalabilidade
 - Tempo para construir e utilizar o modelo
- ◆ Robustez
 - Manipulação do ruído e valores faltosos
- ◆ Interpretabilidade:
 - Compreensão e entendimento fornecidos pelo modelo
- ◆ Qualidade do conhecimento gerado
 - Exemplo: tamanho da árvore de decisão



Aprendizado (Técnicas)

- ◆ Árvores de Decisão
- ◆ Regras de Classificação
- ◆ Modelos Estatísticos
 - Naïve Bayes
 - Bayesian Belief Networks
- ◆ Redes Neurais



◆◆Dúvidas???