

Sistema de Inteligência Computacional para Risco de Óbito em Câncer de Mama

Evolução metodológica e o impacto de dados ricos sobre arquiteturas de ensemble

- Trabalho de Conclusão de Disciplina
- Trilha SEER (Baseline Corrigido) → Trilha METABRIC (Evolução Canônica)

Trilha SEER
(Baseline Corrigido)

Trilha METABRIC
(Evolução Canônica)

Estrutura do Relatório Analítico

Visão Geral


Metodologia

Análise

Resultados

Discussão


Configurações



Asymmetric Cost of Errors in Healthcare


Em saúde, acurácia alta pode esconder erros fatais

O objetivo primário do sistema é prever a classe positiva de óbito observado a partir de dados tabulares (SEER: Status = Dead | METABRIC: Status = Deceased).



Conclusão Visual: O problema é severamente desbalanceado. A otimização deve priorizar **Recall**, **F2-Score** e eliminação de **Falsos Negativos**.

Survival Months foi removido para evitar vazamento de dados



O Erro Original

Usar meses de sobrevida como feature contaminava o modelo com informações de acompanhamento posteriores ao evento clínico.

A Correção Metodológica

Variável foi estritamente excluída do modelo principal. A predição deve ocorrer apenas com base no estado clínico no momento do diagnóstico.

A transição: de um baseline limitado para uma base clínica profunda

Dataset: SEER Corrigido

4.023
registros



- **Perfil:** Dados clínico-patológicos limitados.
- **Papel no Projeto:** O Baseline Corrigido onde o pipeline metodológico foi saneado e blindado.

Dataset: METABRIC Canônico

1.876
registros

- **Perfil:** Rico em quimioterapia, hormonioterapia, radioterapia, biomarcadores (ER, PR, HER2) e subtipo molecular (PAM50).
- **Papel no Projeto:** A Evolução Canônica, demonstrando como dados de alta qualidade elevam o teto do modelo.

Saneamento centralizado e Análise Exploratória de Dados



Dicionário de dados consolidado e sanitização rigorosa de schemas.

Mapeamento explícito da relação de metadados antes de qualquer transformação.

Conclusão da EDA: Diferenças de **distribuição** claras (ex: Idade e NPI) validam o potencial discriminatório da nova base METABRIC.


Transformando sinais clínicos em carga tumoral e nodal

O Limite do SEER

- Apenas proporções simples (node_positive_ratio, advanced_stage_flag).

A Profundidade do METABRIC

- Transformação de variáveis isoladas em indicadores de burden (carga tumoral e carga nodal).
- Categorização baseada em exposição real a tratamentos (rádio, quimio, hormônio).
- Perfis moleculares e atributos fuzzy estruturados para modelagem posterior.



Validação escolhe, Teste apenas reporta



Modelos tabulares e o escopo do comparativo Neuro-Fuzzy

A Competição Real (Modelos Tabulares)

- Logistic Regression
- Random Forest
- ExtraTrees
- GradientBoosting
- HistGradientBoosting
- SVM
- AdaBoost
- MLP
- Ensemble Ponderado

O Requisito Acadêmico (Neuro-Fuzzy)

- **O que NÃO é:** Não é um sistema ANFIS completo de regras autônomas.
- **O que É:** Sistema neuro-fuzzy cooperativo baseado em fuzzificação manual + rede neural MLP.
- **O Objetivo:** Atender ao requisito curricular da ementa e servir como comparativo acadêmico honesto de sistemas híbridos.



0 salto informacional: METABRIC melhora antes mesmo do ensemble

Baseline SEER Corrigido (Regressão Logística)

Accuracy: 0.6807

PR AUC: 0.3525

F2-Score: 0.4832

Recall: 0.6098

Falsos Negativos: 48

Canônico METABRIC (GradientBoosting)

Accuracy: 0.7048

PR AUC: 0.7600


F2-Score: 0.7787

Recall: 0.7953

Falsos Negativos: 44

**0 GradientBoosting no METABRIC supera brutalmente o SEER individual.
A melhoria de qualidade do dado elevou o teto do problema.**

Otimização do Ensemble: Forçando a sensibilidade máxima



A meta não era o modelo global perfeito, mas sim o Ponto Operacional clínico seguro.

- Threshold padrão de 0.50 falharia em capturar risco oculto.
- A Decisão: Threshold calibrado na validação para 0.16.
- Essa calibragem sacrifica precisão para garantir que a curva de sensibilidade (Recall) chegue próxima a 1.0.

O Trade-off Clínico: Erradicação do risco exige tolerância ao alerta falso

Real Living	15	146
Real Deceased	1	214
	Previsto Living	Previsto Deceased

Métricas do Resultado:

Threshold: 0.16
Recall alcançado: 0.9953
F2-Score final: 0.8770

O Custo do Trade-off:

SEER Ensemble: 29 Falsos Negativos | 320 Falsos Positivos.
METABRIC Ensemble: Apenas 1 Falso Negativo | 146 Falsos Positivos.

Insight:

O ensemble é o modelo definitivo para sensibilidade. O ganho extremo de segurança na detecção (apenas 1 caso letal perdido) justifica operacionalmente o ônus analítico de investigar 146 alarmes falsos.

O que a evolução do projeto comprovou



Corrigir metodologia importa

Remover variáveis temporais vazadas (Survival Months) e auditar o pipeline transformou um experimento falho em uma defesa científica blindada.



O dataset eleva o teto do projeto

Progressão do F2: SEER Baseline (0.48) → SEER Ensemble (0.51) → METABRIC Baseline (0.77) → METABRIC Ensemble (0.87). O salto principal veio da qualidade clínica do dado, não apenas da arquitetura.



Nem todo híbrido é o campeão absoluto

Avaliação Neuro-fuzzy honesta. Desempenho empírico (SEER F2: 0.2886 | METABRIC F2: 0.6548) ficou abaixo do GradientBoosting tabular, comprovando que complexidade não supera árvores em dados estruturados profundos.

Limitações metodológicas e o estado final do projeto

Limitações sem maquiagem

- Permanece como Classificação Tabular, não como Survival Analysis formal.
- Uso de bases de dados acadêmicas; sem validação clínica externa ativa.
- Alto volume de Falsos Positivos torna o sistema um filtro preliminar, não uma ferramenta de decisão cirúrgica solitária.

Encerramento e Legado



- O SEER foi saneado e permanece imortalizado como nosso baseline metodológico corrigido.



- O METABRIC validou a nossa tese principal: é a evolução canônica que suporta engenharia clínica avançada.



Próximos Passos: Survival analysis estrita e explicabilidade local por instância.

Apêndice Analítico: Racional e Justificativas Metodológicas

Por que não avaliar usando Acurácia?

O problema é desbalanceado em saúde. Acurácia infla mascarando casos minoritários, omitindo exatamente os falsos negativos que resultam em óbito.

Por que retirar o Survival Months afinal?

Porque sobrevida em meses é informação capturada após o diagnóstico inicial. Prever morte usando o tempo até a morte é Data Leakage cíclico e invalida o poder preditivo clínico.

O Ensemble foi otimizado no conjunto de Teste?

Não. O Threshold de 0.16 e os pesos de votação foram exclusivamente definidos no conjunto de Validação isolado. O Teste apenas reportou os números finais.

O módulo Neuro-fuzzy implementado é um ANFIS?

Não. É um modelo cooperativo estruturado em fuzzificação manual + rede neural MLP, mantido como comparativo acadêmico e prova de conceito híbrida, mas que empiricamente não liderou as métricas.